## Reading the First Books

Automatic transcription for multilingual, early modern printed documents

Hannah Alpert-Abrams







## Reading the First Books

Project Team: Sergio Romero, Hannah Alpert-Abrams, Maria Victoria Fernández (UT Austin)

Computer Science: Dan Garrette (U. of Washington), Taylor Berk-Kirkpatrick (UC Berkeley)

Mesoamerican Languages: Stephanie Wood (U. of Oregon), Kelly McDonough, Adam Coon (UT Austin)

**eMOP** and **Primeros Libros**: Laura Mandel, Anton Duplessis, Elizabeth Grumbach (Texas A&M University), Trey Dockendorf, Bryan Tarpley, Matt Christy

University of Texas Libraries: Aaron Choate





christiana. Fo 10.
Mic.ca ypampa inic yehuantin quicui lozque ininemiliztzin ynictlalticpac mo nemitico in totecuyo Jesu rporintleyn quimochihuilico in quimotemachtilico: inictehuantin tictotepotztoquilizque y nitemachtilitzin. Mic. Latlehuatl ino quicuiloque in nahuintin in Luangelistame.

Ciffic. La yehuatl ynauhtlamantli yn Euangelio ynipan mopia ynirquich totech monequi in ticneltocazque yn tic chihuazq. Yhua intleyn tictlalcahuizq intictelchihuazque. Yhuan intley tichi huazq yye yrach totech monequi. Lluh yntlacamo ticneltocazque in tlein quicuilotiaque çan nimă ahueltitomaquiptizqui.

Milo.nicmatiznequi ynictiazque ynilbuicac cuir sa yeyyo ticneltocazque yn

oquicuilotiaque.

Mic. ca itlacamo tictopielică tictone miliztican initeotena puatiltzin, yyebuă tin inquicauptia que caniman apuel tiaz que ynilpuicac.

b ij





chaistiana. 10. Mic.ca ypampa inic yehuantin quicui losque ininemilistsin ynictlalticpacmo nemitico in totecuyo Jesu rporintleyn quimochibuilico in quimotemachtilico: inictebuantin tictotepotztoquilizque y nitemachtiltzin. MMo. Latlehuatl ino quicuiloque in nabuintin in Luangelistame. Milic. La rebuatl gnaubtlamantli yn Euangelio ynipan mopia ynirquich totech monequi in ticneltocazque entic chibuają. Y bua intleyn tictlalcabuiją intictelchibuazque. I huan intley tichi huazą rze grąch totech monequi. Aub untlacamo ticneltocazque intlein quicuilotiaque can nima abueltitomaquirtizqui. Ano.nicmatiznequi ynictiazque ynilbuicac cuir ça yeyyo ticneltocazque yn oquicuilotiaque. Mic. ca itlacamo tictopielică tictone miliztican initeotena buatiltzin, yyebua tin inquicaubtiaque caniman abuel tias que ynilbuicac.

chri|tiana. Fo 10.

¶Nic. ca ypampa inic yehuantin quicui lozque ininemilztzin yn ictlalticpacmo nemitico in totecuyo Je|u x\~po: intleyn quimochihuilico in quimotemachtilico: inictehuantin tictotepotztoquilizque y nitemachtiltzin. ¶No. Catlehuatl ino quicuiloque in nahuintin in Euangeli|tame.

¶Nic. Ca yehuatl yn auhtlamantli yn Euangelio yn ipan mopia yn ixquich totech monequi in ticneltocazque yn tic chihuaz\~q. Yhu\~a intleyn tictlalcahuiz\~q íntictelchihuazque. Yhuan intley tichi huaz\~q yye yx\'qch totech monequi. Tluh yntlacamo ticneltocazque in tlein quicuilotiaque çan nim\~a ahueltitomaquixtizqui.

¶No. nicmatiznequi yn ic tiazque yn ilhuicac cuix ça yeyyo ticneltocazque yn oquicuilotiaque.

¶Nic. ca \~itlacamo tictopielic\~a tictone miliztican initeotenahuatiltzin, yyehu\~a tin inquicauhtiaque caniman ahuel tiaz que yn ilhuicac.

o ij



Christiana. Fo 10.

Mic.ca ypampa inic yehuantin quicui lozque ininemiliztzin ynictlalticpac mo nemitico in totecuyo Jesu ppozintleyn quimochihuilico in quimotemachtilico: inictehuantin tictotepotztoquilizque y nitemachtilitzin. A Mo. Latlehuatl ino quicuiloque in nahuintin in Euangelistame.

Mic. La gehuatl gnauhtlamantli yn Euangelio ynipan mopia ynipquich totech monequi in ticneltocazque yn tic chihuazq. Yhua intleyn tictlalcahuizq intictelchihuazque. Yhuan intley tichi huazq yye yrach totech monequi. Lluh yntlacamo ticneltocazque in tlein qui-cuilotiaque çan nimā ahueltitomaquiptizqui.

Monicmatiznequi ynictiazque ynilbuicac cuir ça yeyyo ticneltocazque yn oquicuilotiaque.

Mic. ca itlacamo tictopielică tictone miliztican initeotena puatiltzin, y ze buă tin inquicauptia que caniman a puel tiaz que ynilbuicac.

b ij

o — M r $^-$  v $^-$ SO |> $^+$ 00 Cv O — « r $^-$  -«t- « $^+$ 0 r $^-$ 00 Oso — r $^+$ 0 vo SO vO \0 vO vO vO vO nO so \0 sOvO vososOnOvOvOsOvOvO

00 (7s O — «\*< '♠N ^ w^sO r-»00 (7s o «- n r^ 't- «^VO f>.00 Cv o w^ w^vO sovovosovovovo>ovo r\*\* r^r^i^i^c^r>.c^r>. r\*\*oo

VO r\*\*00 Cv o — \*^ «^ -^ «^SO t>i30 J\ o — r«

o — M r^ -^ v^SO |> »00 Cv O — « r^ -«t- «^\o r-^oo Oso — r^ vo SO vO \0 vO \*0 vO vO nO so \0 sOvO vososOnOvOvOsOvOvO

00 (7s O — «\*< '♠N ^ w^sO r-»00 (7s o «- n r^ 't-



# Ocular: Historical Document Recognition System

Taylor Berg-Kirkpatrick et al., UC Berkeley (2013)

- 1. Material Analysis: Font Model
- 2. Linguistic Analysis: Language Model



## Wandering baseline

§. Los verbales en liztli, significan

Uneven inking

positionem con pletium. Y en la d. 16 q.

Unfamiliar Typefaces

AMoteycauhtzi.tleypampa ynoquim



## Variable Orthography



## Multilingual Text

Ay proprio vocablo de logro, que es tetechtlaixtlapanalizeli, tetechtlamieccaquixtilizeli, ypara dezir diste alogro? Cuix tetech otitlaix tlapan, cuix tech otitlamieccaquixti?



## Modifying OCR for Colonial Documents

- 1. Multiple Languages
- 2. Historical Orthography
- 3. Modernized Transcription



#### Multiple Languages

"¶ Q¿nid dicendum de Ocnamacaque. f. de las pu|queras, o taberneros, qui vendunt vinum indorum, indis, quod dicitur Octli .&. etiam de iis qui eis venduntvr no verum Hi|

1 Q uid dicendum de Ocnamacaque. s. de las pulqueras, o taberneros, qui vendunt vi-27 num Indorum, Indis, quod dicitur Octli :& etiam de ijs qui eis vendunt vinū verum His

Bautista, Advertencias, 1601



#### Historical Orthography

mais Religiofos, & em muitas cafas particulares de peñoas illustres. E logo os Reitores \~qe taõ juntos, derão o mefmo avifo a feus Collegios, fendo em todos, & cada hum delles recebida a nova com as mefmas demõftrações, & aluoroço de alegria começando cada hũa tratar do que conuinha pa ra a fertejar como fizeraõ, & em feus logares fe dirá.\_

mais Religiosos, & em muitas casas particulares de pessoas illustres. E logo os Reirores que erao juntos, derão o mesmo aussoa seus Collegios, sendo em todos, & cada hum delles recebida a noua com as mesmas demostrações, & aluoroço de alegria, começando cada húa tratar do que convinha para a seste jar, como sizerao, & em seus lugares se dirà.

Relações das sumptuosas festas..., Lisbon 1622 [Lisa Voigt, Laura Fernandez-Gonzalez, Iris Kantor, Ângela Barreto Xavier]





#### Normalization

Norm.: illustres. E logo os Reitores que tao juntos, derão o mesmo Hist.: illustres. E logo os Reitores \~qe tao juntos, derão o mesmo

Norm.: aviso a seus Collegios, sendo em todos, & cada hum delles Hist.: avifo a feus Collegios, fendo em todos, & cada hum delles

Norm.: recebida a nova com as mesmas demonstrações, & alvoroço Hist.: recebida a nova com as mesmas demostrações, & aluoroço

Norm.: de alegria começando cada huma tratar do que convinha pa-Hist.: de alegria começando cada huma tratar do que conuinha pa

illustres. E logo os Reirores q erao juntos, derão o mesmo ausso a seus Collegios, sendo em todos, & cada hum delles recebida a noua com as mesmas demostrações, & aluoroço de a egria, começando cada hú a tratar do que convinha para a seste jar, como sizerao, & em seus lugares se dirà.



## Future Work



#### Normalization

Norm.: In teu iutica ta ueuetl, in titlatzca, into-Hist: In teu iutica ta ueuetl, in titlatzca, intoteoyotica tawewetl

morpheme parsing

Norm: ca metl, in toiauhquauitl, in tepiltzi sancta Hist: ia metl, in taiauhquauitl, in tipiltzi fancta

Norm: yglesia. in toquichtli xipapaqui, ximotla-Hist: Iglefia. in toquichtli xipapaqui, ximotla

In teuiutica taueuetl, in titlatzca, into iametl, in taiauhquauitl, in tipiltzi sancta Iglesia, in toquichtli xipapaqui, ximotla

Sahagún, *Psalmodia*, 1583





#### Normalization

over correction

Norm: lī yiollo, oquimopanatili in cemana-Hist: lī yiollo, oquimmopanauili in cemana-

false substitution

Mod: oac tlaca. Hist: oac tlaca.

Norm: In iehoatzi sant joseph. ymaceoal omo-Hist: In iehoatzi fant fofeph. imaceoal omu

correct substitution!

Norm: chiuh, in quimonapalhuiz in dios ypiltzi, Hist: chiuh, in quimonapalhuiz in dios ipiltzi,

li viollo, oquimmopanauili in cemanaoactlaca. Sillo vooroom salizanis vas

In iehoatzi sant Ioseph, imaceoal omu chiuh, in quimonapalhuiz in dios ipiltzi,

Sahagún, *Psalmodia*, 1583





#### Integrating with eMOP



#### FirstBooks Dashboard

Initiative for Digital Humanities, Media, and Culture



 Job Queue
 545

 In-Progress:
 0

 Await Postprocess:
 0

 Failed:
 9

 Ingested:
 33

 Ingest Failed:
 0

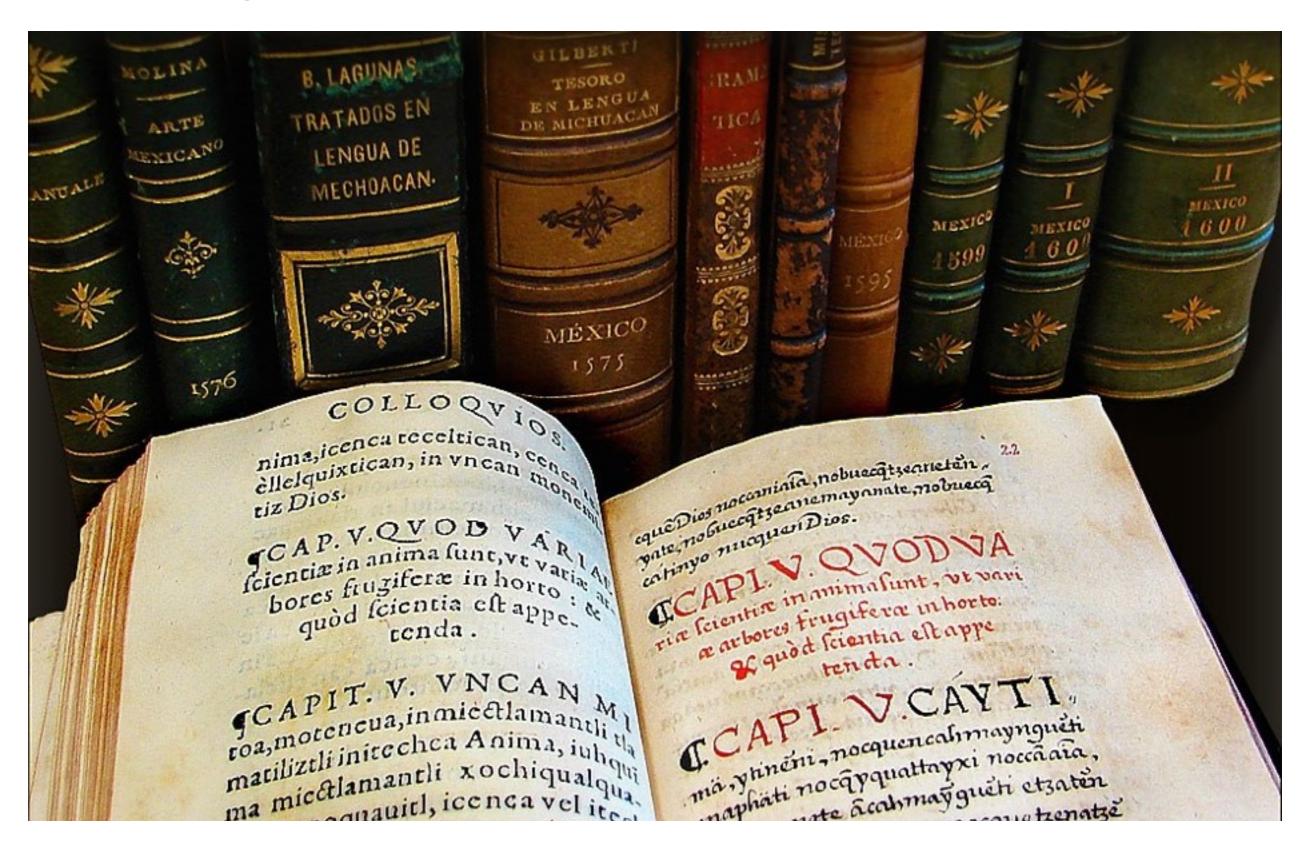
 TOTAL:
 587

Select All Schedule Selected Schedule All Set Print Font for Selected Works

Show 25 entries

Status		Collection	ID ф	Book ID 🍦	GT Number \$	Language \$	Title \$	Author &	Font	OCR Date	OCR Engine	OCR Batch	Juxta	RETAS
10-0-0-0	۵	FirstBooks	101	pl_plfx_008		mixtec	Vocabulario en lengua misteca		roman		Ocular	42: 01_testAllBooks	N/A	N/A
10-0-0-0	۵	FirstBooks	102	pl_plfx_009		mixtec	Vocabulario en lengua misteca		roman		Ocular	42: 01_testAllBooks	N/A	N/A
10-0-0-0	S	FirstBooks	103	pl_tamu_006		mixted	Doctrina cristiana en lengua misteca		blackletter		Ocular	42: 01_testAllBooks	N/A	N/A
0-0-0-0	۵	FirstBooks	104	pl_tecm_074		mixtec	Vocabulario en lengua misteca		roman				N/A	N/A
10-0-0-0	چ	FirstBooks	105	pl_befk_001		nahuati	Vocabulario en Lengua Castellana y Mexicana				Ocular	42: 01_testAllBooks	N/A	N/A
							Vocabulario en							

#### Transcribing the Primeros Libros





## "Reading the First Books"

sites.utexas.edu/firstbooks

Hannah Alpert-Abrams halperta@gmail.com





